NoSQL avec MongoDB

Cours 7 - Analyse des données

Steve Lévesque, Tous droits reservés © où applicables

Table des matières

1 Utilité de l'analyse des données

2 Différence entre l'analyse et le nettoyage des données

3 Description du Dataframe

4 Groupement des données par attribut

5 Visualisation avec Matplotlib

Utilité de l'analyse des données

L'analyse des données est une étape préalable, ou du moins fortement recommandée de faire avant toute chose, pour avoir un aperçu de plusieurs facteurs importants pouvant impacter l'entraînement d'un modèle d'Intelligence Artificielle (AI).

Par la suite, les décisions importantes et le nettoyage des données sont **beaucoup plus faciles** à accomplir.

Utilité de l'analyse des données

Voici une liste simple* des opérations d'analyse que nous allons voir :

- Description du Dataframe.
- Groupement des données par attribut.
- Visualisation graphique avec Matplotlib.

*il existe beaucoup plus d'opérations.

Différence entre l'analyse et le nettoyage des données

Avantages de Python :

- Facile à apprendre
- Simple et rapide de programmer sur des "deadlines" courts
- Open-source
- Compatible avec plusieurs domaines (Web, AI, etc.)

Description du Dataframe

La description du Dataframe Pandas permet d'avoir un tableau complet de la disparité statistique des données pour toutes les colonnes (attributs) de l'objet en question.

Très utile pour voir les **débalancements des classes**, les erreurs dans le nettoyage des données, et voir la moyenne et la déviation standard (à quel point la valeur est proche de la moyenne).

	#	Total	HP	...	Defense
count	800.000000	800.00000	800.000000	...	800.000000
mean	362.813750	435.10250	69.258750	...	73.842500
std	208.343798	119.96304	25.534669	...	31.183501
min	1.000000	180.00000	1.000000	...	5.000000
25%	184.750000	330.00000	50.000000	...	50.000000
50%	364.500000	450.00000	65.000000	...	70.000000
75%	539.250000	515.00000	80.000000	...	90.000000
max	721.000000	780.00000	255.000000	...	230.000000

Description du Dataframe

```
# Steve Levesque, All rights reserved where applicable
import pandas as pd
from pymongo import MongoClient

client = MongoClient()
db = client.admin
collection = db.Pokemons
documents = collection.find()

df = pd.DataFrame(documents)

# Descriptive Statistics: Show stats of all columns of the dataframe.
print(df.describe())
```

Groupement des données par attribut

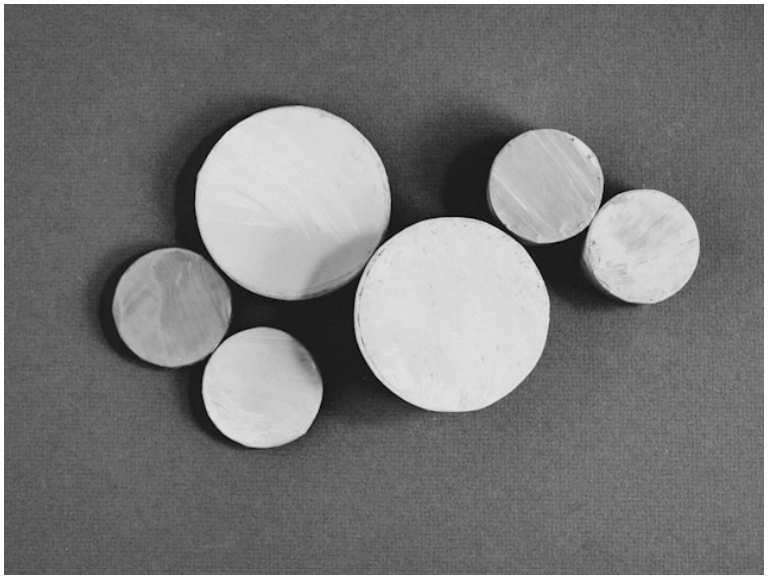

Les groupements permettent d'avoir les données rassemblées par grappe ("clusters") vis-à-vis une caractéristique commune.

Ensuite, les grappes peuvent avoir des opérations statistiques appliquées de manière isolée en silo. Relativement utile pour avoir de l'information pure sur un sous-ensemble de données.

Groupement des données par attribut

Nous allons voir comment les données sont regroupées par un attribut avec valeurs semblables entre les entrées.

Par exemple, les Pokémons ont tous un type (Eau, feu, etc.) pouvant se répéter d'un Pokémon à un autre. Il serait intéressant de regrouper les Pokémons "Fire" ensemble, "Water" ensemble, et ainsi de suite.

Groupement des données par attribut

```
# Steve Levesque, All rights reserved where applicable
import pandas as pd
from pymongo import MongoClient

client = MongoClient()
db = client.admin
collection = db.Pokemons
documents = collection.find()

df = pd.DataFrame(documents)

# Grouping and Aggregation :
# Pokemons by primary type, max of each group's HP and Attack.
grouped = df.groupby('Type 1')
print(grouped['HP'].max())
print(grouped['Attack'].max())
```

Visualisation avec Matplotlib

Il est important de ne pas être trop confiant si un doute occupe notre esprit.

Pour être complètement sûre de la topologie des données, une image vaut 1000 mots !

Les graphiques avec Matplotlib permettent de représenter visuellement les données d'un Dataframe directement à même son objet.

Visualisation avec Matplotlib

Listing: https://stackoverflow.com/questions/15910019/annotate-data-points-while-plotting-from-pandas-dataframe

```
# Steve Levesque, All rights reserved where applicable
import matplotlib.pyplot as plt, pandas as pd
from pymongo import MongoClient

client = MongoClient()
db = client.admin
collection = db.Pokemons
documents = collection.find()

df = pd.DataFrame(documents)

# Data Visualization: All Pokemons scattered by HP.
print(df['HP'].describe())
fig, ax = plt.subplots()
df.plot(kind='scatter', x='#', y='HP', color='red', ax=ax)
for k, v in df.iterrows():
    ax.annotate(v['Name'] + ", " + str(v['HP']), (v['#'], v['HP']))
plt.show()
```

Visualisation avec Matplotlib

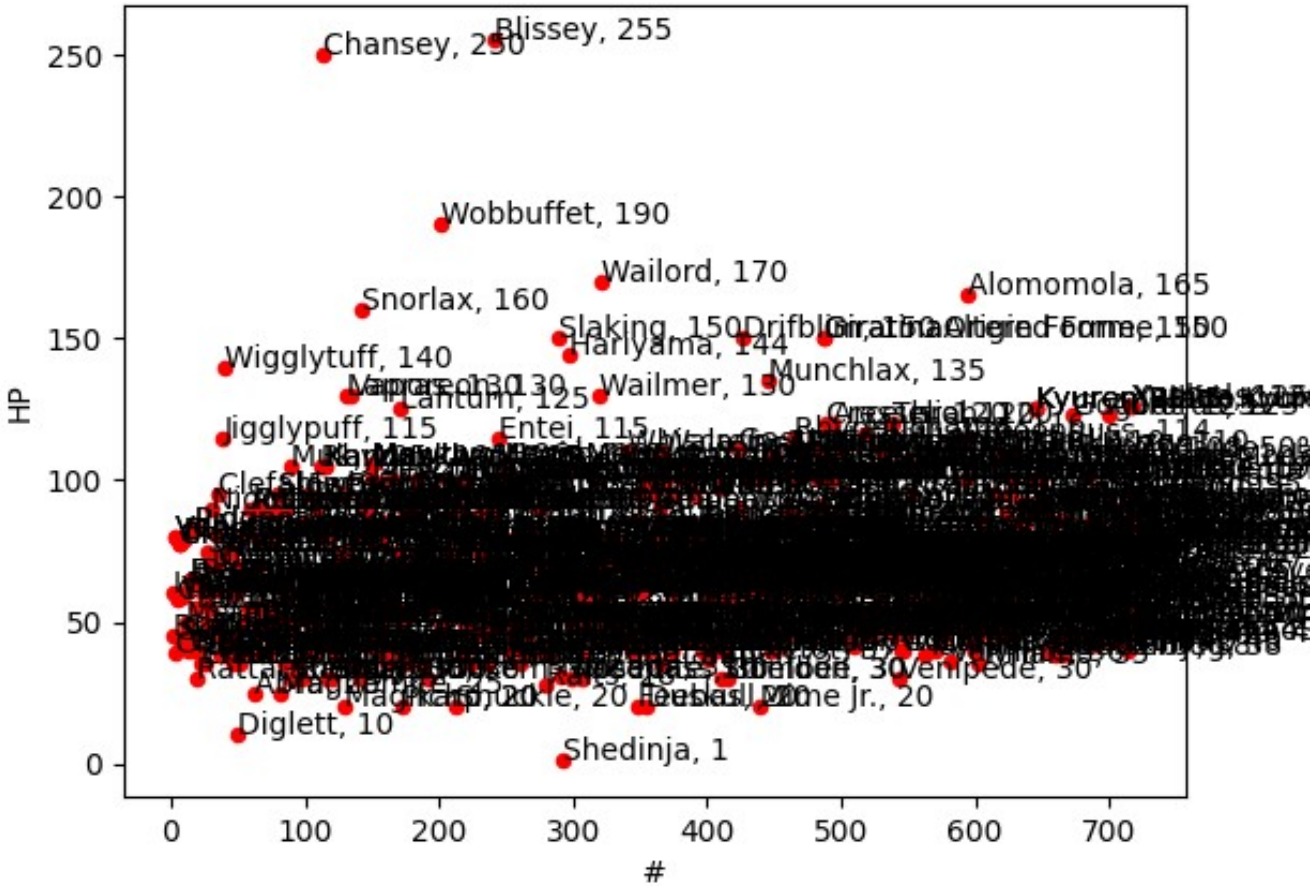

Figure: Visualisation de tous les Pokémon par “scatter plot” en fonction de leur HP.

Visualisation avec Matplotlib

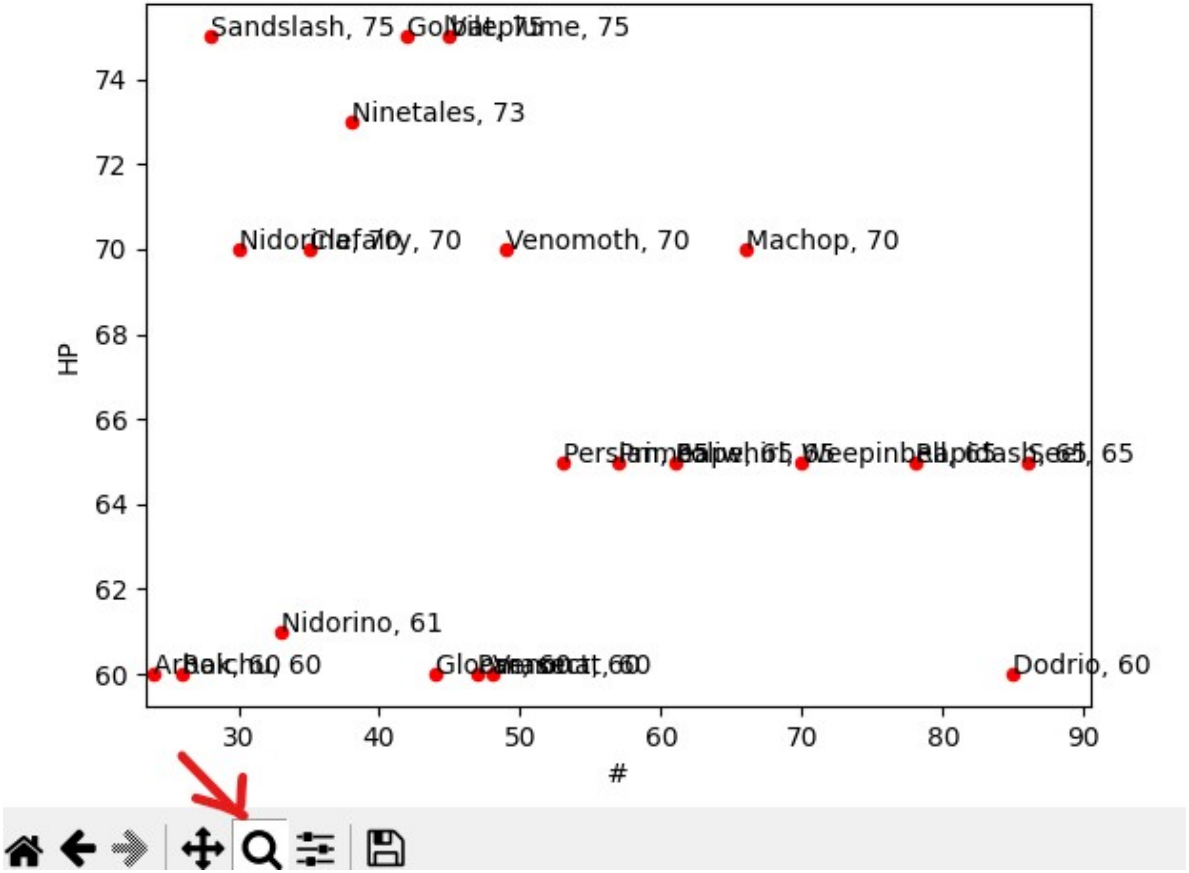

Figure: Il est possible de faire un Zoom avec l'interface interactif.

Bibliographie

- https://medium.com/@stevencibambo/loading-data-from-mongodb-with-pymongo-for-analysis-c0
- https://stackoverflow.com/questions/15910019/annotate-data-points-while-plotting-from-pandas-datafr